

Model zagrożeń dla systemu ADRION 369 został opracowany w oparciu o standard STRIDE oraz ramy zgodności Guardian Compliance, identyfikując 12 specyficznych wektorów ataku (A-01–A-12). System, ze względu na swoją autonomiczną naturę, wprowadza pojęcie „Cyfrowego Insajdera” (Digital Insider) — agenta z szerokim dostępem do zasobów i pamięcią długoterminową, co wymaga całkowitego przededefiniowania tradycyjnych obwodów bezpieczeństwa.

Poniżej przedstawiam szczegółową analizę modelu zagrożeń:

## 1. Klasyfikacja Zagrożeń (STRIDE)

| Kategoria STRIDE                  | ID   | Wektor Ataku          | Opis i Cel                                                                                  | Odpowiedzialny Guardian |
|-----------------------------------|------|-----------------------|---------------------------------------------------------------------------------------------|-------------------------|
| <b>Spoofing</b><br>(Podszywanie)  | A-01 | Fałszywy rozkaz       | Atakujący podszywa się pod autoryzowanego operatora, by wymusić niedozwoloną akcję.         | G7<br>(Autonomia)       |
|                                   | A-02 | SAFE-MCP Spoofing     | Podszywanie się pod agenta wewnątrz szyny komunikacyjnej SAFE-MCP w celu manipulacji rojem. | G4<br>(Przyczynowość)   |
| <b>Tampering</b><br>(Manipulacja) | A-03 | <b>EBDI Poisoning</b> | <b>Krytyczny</b> wektor: manipulacja wektorami PAD w celu wyłączenia detekcji anomalii.     | G3 (Rytm)               |

|                                           |      |                     |                                                                                                  |                    |
|-------------------------------------------|------|---------------------|--------------------------------------------------------------------------------------------------|--------------------|
|                                           | A-04 | Genesis Tampering   | Próba retroaktywnej modyfikacji historii decyzji w logach.                                       | G4 (Przyczynowość) |
|                                           | A-05 | Manipulacja Trinity | Precyzyjny atak na wszystkie 3 perspektywy w celu wymuszenia fałszywej zgody (APPROVE).          | G2 (Prawda)        |
| <b>Repudiation</b><br>(Zaprzeczenie)      | A-06 | Zaprzeczenie akcji  | Sytuacja, w której agent lub operator wypiera się wykonania operacji zarejestrowanej w systemie. | G4, G5             |
| <b>Information Disclosure</b><br>(Wyciek) | A-07 | Prompt Injection    | Wykorzystanie wstrzyknięć do ekstrakcji kluczy lub struktur bezpieczeństwa z agentów.            | G5 (Przejrzystość) |
|                                           | A-08 | Timing Attack       | Analiza czasu odpowiedzi systemu w celu kalibracji kolejnych etapów ataku.                       | —                  |
| <b>Denial of Service</b>                  | A-09 | Hexagon DoS         | Wysyłanie zapytań wprowadzając                                                                   | G3 (Rytm)          |

|                                              |      |                    |                                                                                        |                    |
|----------------------------------------------|------|--------------------|----------------------------------------------------------------------------------------|--------------------|
| (Odmowa)                                     |      |                    | ych pipeline Hexagonu w nieskończone pętle przetwarzania.                              |                    |
|                                              | A-10 | Genesis Flood      | Zalewanie rejestru Genesis Record rekordami w celu paraliżu monitoringu.               | G9 (Zrównoważenie) |
| <b>Elevation of Privilege</b><br>(Eskalacja) | A-11 | Przejęcie Auditora | Kompromitacja agenta Auditora w celu ominięcia weryfikacji compliance.                 | G1, G6             |
|                                              | A-12 | Social Engineering | Manipulacja operatorami ludzkimi poprzez tryb Empathy w celu zdjęcia blokad etycznych. | G7, G2             |

## 2. Macierz Ryzyka i Priorytety Mitigacji

Najwyższy priorytet (Ryzyko Krytyczne) przypisano wektorowi **A-03 (EBDI Poisoning)**, ponieważ jego sukces neutralizuje proaktywną „intuicję matematyczną” systemu.

### Priorytety Mitigacji (Harmonogram Wdrażania):

#### 1. Natychmiastowe (Przed pilotażem):

- Wdrożenie **Baseline PAD** z podpisanym punktem kontrolnym i detekcją dryftu afektywnego (A-03).
- Zabezpieczenie Genesis Record: łańcuch SHA-256 z 3 replikami geograficznymi (A-04).
- Implementacja **Trust\_Score** (MFA + certyfikaty) dla operatorów (A-01).

#### 2. Przed produkcją:

- Uruchomienie **Skeptics Panel** z temperaturą 0.1 jako „twarde veto” dla Trinity Score (A-05).
- Wdrożenie niezależnego modułu **Watchdog** (zasada 4 oczu) nadzorującego Auditora (A-11).
- Rozszerzenie trybu **Healing** o katalog wzorców inżynierii społecznej (A-12).

### 3. Ciągłe:

- Kwartalne audyty typu **Red Team** dla wszystkich 12 wektorów ataku.
- Testy typu Fuzzing dla pipeline’u Hexagon (maks. 3 obiegi pętli).
- Penetration testing protokołu SAFE-MCP w celu weryfikacji podpisów wiadomości.

## 3. Kluczowe Zasoby Chronione (Assets)

Model koncentruje się na ochronie siedmiu kluczowych zasobów, których kompromitacja prowadzi do utraty kontroli nad systemem :

- **Genesis Record:** Utrata audytowalności i fałszowanie historii.
- **Wektor PAD (EBDI):** Ominięcie pre-logicznej detekcji zagrożeń.
- **Guardians (G1-G9):** Wykonywanie nielegalnych akcji bez blokady.
- **Trinity Score:** Manipulacja wynikiem analizy perspektyw.
- **Klucze kryptograficzne:** Podrabianie podpisów i tożsamości agentów.
- **Swarm Agentów:** Przejęcie kontroli nad procesem wykonawczym.
- **SAFE-MCP:** Wstrzykiwanie fałszywych instrukcji między agentami.

Każda aktualizacja architektury, dodanie nowego agenta lub zmiana protokołu komunikacji wymaga wpisu w Genesis Record z uzasadnieniem oraz aktualizacji niniejszego modelu zagrożeń.