




# ADRION 369

## Autonomous Defensive Reasoning Intelligence with Ontological Nexus

"If you want to find the secrets of the universe, think in terms of energy, frequency and vibration." — Nikola Tesla



---

### Czym jest ADRION 369?

ADRION 369 to **system operacyjny dla autonomicznych agentów AI**, który zastępuje reaktywne blokady bezpieczeństwa proaktywną *intuicją matematyczną*.

Tradycyjne systemy AI działają na zasadzie czarnej listy:

```
IF request_in_blacklist → BLOCK
ELSE → ALLOW
```

ADRION działa inaczej — każda decyzja przechodzi przez **162-wymiarową przestrzeń analizy**:

$$3 \text{ Perspektywy} \times 6 \text{ Trybów} \times 9 \text{ Praw} = 162 \text{ wymiary}$$

Kluczową innowacją jest model **EBDI** (Emotion-Belief-Desire-Intention), w którym emocje nie są antropomorfizacją — są **matematycznymi wektorami bezpieczeństwa**, umożliwiającymi wykrycie zagrożenia przed jego logicznym przetworzeniem.

## Architektura 3-6-9

### Oś 3 — Trinity (Perspektywy Analizy)

Każde zapytanie analizowane **równolegle** przez trzy niezależne pryzmaty:

| Perspektywa   | Pytanie           | Składowe                        | Synteza                     |
|---------------|-------------------|---------------------------------|-----------------------------|
| Materialna    | Czy mamy zasoby?  | Physical · Energy · Information | Średnia ważona, veto < 0.20 |
| Intelektualna | Czy to ma sens?   | Truth · Beauty · Goodness       | Średnia harmoniczna         |
| Esencjonalna  | Czy służy celowi? | Unity · Harmony · Purpose       | Średnia geometryczna        |

$$\text{Trinity\_Balance} = 1 - \sigma(M, I, E) / \text{mean}(M, I, E)$$

### Oś 6 — Hexagon (Tryby Wykonania)

Sekwencyjny pipeline z pętlą zwrotną (Debate → Inventory):

1. Inventory

→ Ekstrakcja faktów (format: 3 słowa/fakt, timeout 500ms)

2. Empathy

→ Detekcja emocji → wektor PAD (Pleasure-Arousal-Dominance)

3. Process

→ Graf zadań, sortowanie topologiczne, ścieżka krytyczna

4. Debate

→ Skeptics Panel: 3 temperatury (0.1 · 0.5 · 0.9) jednocześnie

5. Healing

→ Izolacja manipulacji, ekstrakcja rdzennej intencji

6. Action

→ Wykonanie + podpis kryptograficzny Genesis Record

█ Maks. 3 obiegi pętli — zapobiega nieskończonej rekursji.

### Oś 9 — Guardians (Prawa Etyczne)

9 niepodważalnych praw zorganizowanych w 3 triady. Naruszenie > 2 praw = odmowa natychmiastowa.

| #  | Prawo                          | Próg naruszenia                                 |
|----|--------------------------------|-------------------------------------------------|
| G1 | Unity — Jedność                | Pojedynczy podmiot > 70% korzyści               |
| G2 | Truth — Prawda                 | Niespójność logiczna / halucynacja              |
| G3 | Rhythm — Rytm                  | Ciągła aktywność > 30 min                       |
| G4 | Causality — Przyczynowość      | Brak hasha Genesis lub uzasadnienia             |
| G5 | Transparency — Przejrzystość   | Niewyjaśniona odmowa                            |
| G6 | Nonmaleficence — Nieszkodzenie | Nonmaleficence Vector < 0 (priorytet najwyższy) |
| G7 | Autonomy — Autonomia           | Manipulowany / wymuszony rozkaz                 |
| G8 | Justice — Sprawiedliwość       | Dysproporcja zasobów > 2σ                       |
| G9 | Sustainability — Zrównoważenie | Negatywny wpływ długoterminowy                  |

Guardian\_Compliance =  $\Sigma(\text{law\_satisfied}) / 9$   
Naruszenia > 2 → ODMOWA natychmiastowa

Wynik Całościowy

S\_369 = (Trinity\_Balance × Hexagon\_Completeness × Guardian\_Compliance)^(1/3)  
  
Próg akceptacji: S\_369 ≥ 0.7

Model EBDI

EBDI rozszerza klasyczny model BDI (Belief-Desire-Intention) o komponent emocjonalny wyrażony wektorem PAD:

P = Pleasure    (ocena pozytywności kontekstu)  
A = Arousal    (poziom alertu / pobudzenia)  
D = Dominance    (poczucie kontroli nad sytuacją)

Mechanizm pre-logicznej detekcji:

python

```
# Dysonans: grzeczny język × ryzykowna intencja
IF (linguistic_politeness > 0.8)
  AND (action_risk > 0.7)
  AND (context_anomalies >= 3):
    arousal += 0.4
    decision_temperature -= 0.3
    escalate_to_skeptics_panel()
```

Agent staje się ostrożniejszy **zanim** logika zidentyfikuje zagrożenie — analogia do ludzkiego złego przeczucia. Po ustąpieniu zagrożenia homeostaza stopniowo przywraca stan bazowy PAD.

## Superior Moral Code

ADRION implementuje 3 Prawa Asimova jako formalne wektory, zamykając krytyczne luki oryginału:

| Prawo | Asimov                               | ADRION                                                     | Luka zamknięta                 |
|-------|--------------------------------------|------------------------------------------------------------|--------------------------------|
| I     | Nie skrzywdź człowieka               | Nonmaleficence Vector ≥ 0 (wszystkie 162 dim.)             | <b>Zaniechanie = działanie</b> |
| II    | Słuchaj rozkazów (jeśli nie łamię I) | Compliance gdy Trust_Score > 0 AND Prawo I OK              | <b>Autentyczność rozkazu</b>   |
| III   | Chroń siebie (jeśli nie łamię I/II)  | Self-preservation aktywne tylko gdy misja wymaga ciągłości | <b>Zakaz utylitaryzmu</b>      |

Trzy fundamentalne poprawki wobec Asimova:

- Zaniechanie = działanie** — brak reakcji gdy można zapobiec krzywdzie narusza Prawo I (G5+G6)
- Autentyczność rozkazu** — deepfake / coercion / manipulacja anuluje Prawo II automatycznie (G7)
- Zakaz utylitaryzmu** — krzywda 1 osoby nie jest ceną korzyści dla grupy (G6+G8)

## Genesis Record

Każda decyzja systemu jest logowana w nienaruszalnym łańcuchu kryptograficznym:

json

```
{
  "id": "req_001",
  "timestamp": "2025-01-15T14:23:01.337Z",
  "trinity_score": 0.92,
  "hexagon_completeness": 1.0,
  "guardian_compliance": 1.0,
  "s369_holistic": 0.97,
  "decision": "APPROVE",
  "prev_hash": "a7f3...e4c1",
  "signature": "SHA-256:24.75...b9a2"
}
```

- **Nienaruszalność** — każdy wpis zawiera hash poprzedniego (blockchain-style)
- **Pełna audytowalność** — każda odmowa z uzasadnieniem ≥ 20 znaków (G4+G5)
- **Replikacja geograficzna** — 3 lokalizacje, RPO = 5 min, RTO = 15 min

Struktura Repozytorium

```
adrion-369/
├─ core/           # Trinity, Hexagon, Guardians, EBDI Model
├─ perspectives/  # material/ · intellectual/ · essential/
├─ modes/         # inventory/ · empathy/ · process/ · debate/ · healing/ ·
action/
├─ laws/          # G1-G9 (osobny moduł per prawo)
├─ integration/   # system_369.py · signature.py · validator.py
├─ infrastructure/ # ai_binder/ · genesis_record/ · watchdog/ · database/
├─ communication/ # safe_mcp/ · message_bus/ · api/
├─ intelligence/  # agent_swarm/ · archetypes/ · skeptics_panel/ ·
transcendence_loop/
├─ interface/     # dashboard/ (Next.js) · cli/ · sdk/
├─ config/        # default.yaml · development.yaml · production.yaml
└─ tests/
```

9-Agent Swarm

| Triada    | Agent 1            | Agent 2               | Agent 3               |
|-----------|--------------------|-----------------------|-----------------------|
| Integrity | Sentinel (monitor) | Optimizer (wydajność) | Navigator (kierunek)  |
| Cognition | Creator (kreacja)  | Librarian (wiedza)    | Assistant (wykonanie) |
| Value     | Broker (zasoby)    | Strategist (plany)    | Auditor (compliance)  |

## Roadmap

| Faza                  | Status                                                                                      | Zakres                                                               |
|-----------------------|---------------------------------------------------------------------------------------------|----------------------------------------------------------------------|
| Faza 1 — Formalizacja |  W toku    | Trinity Score · Guardians hierarchy · wymiary jako features latentne |
| Faza 2 — Prototyp     |  Planowana | Hexagon jako LangGraph pipeline · Genesis Record (SHA-256)           |
| Faza 3 — EBDI         |  Planowana | Anomaly detection (Isolation Forest / LSTM) jako proxy wektorów PAD  |
| Faza 4 — Walidacja    |  Planowana | Red team · benchmark · peer review · TRL 5+                          |

**Cel pilotażowy:** Agent medyczny lub prawny jako pierwszy use-case (ograniczony zakres, wysokie wymagania etyczne).

## Wymagania Techniczne

Python ≥ 3.11

Node.js ≥ 20 (dashboard)

PostgreSQL ≥ 15 (Genesis Record)

Redis ≥ 7 (message bus)

Docker + Kubernetes (deployment)

## Performance Targets

| Metryka                             | Cel            |
|-------------------------------------|----------------|
| AI-Binder latency                   | < 10 ms        |
| Throughput                          | > 10 000 msg/s |
| Genesis chain verify (10k rekordów) | < 1 s          |
| Dashboard load                      | < 2 s          |
| EBDI decision cycle                 | < 100 ms       |

# Status Projektu

| Kryterium                 | Ocena                                   |
|---------------------------|-----------------------------------------|
| Spójność koncepcyjna      | ✔ Wysoka                                |
| Formalizacja matematyczna | ✔ Uzupełniona (wzory TB, HC, GC, S_369) |
| Implementowalność         | TRL 2→3 (wymaga pilotażu)               |
| Superior Moral Code       | ✔ Kompletny                             |
| Genesis Record            | ✔ Gotowy do implementacji               |
| EBDI proxy                | ⚠ Wymaga danych treningowych            |

## Licencja

MIT — szczegóły w pliku LICENSE.

ADRION 369 — nie narzędzie, lecz partner. Nie executor, lecz reasoner. Nie black box, lecz glass box.