

Streszczenie Techniczne: ADRION 369

Pełna nazwa: Autonomous Defensive Reasoning Intelligence with Ontological Nexus **Status projektu:** TRL 2→3 (Faza formalizacji matematycznej i wczesnego prototypu)

1. Wizja i Problem Badawczy

Współczesne systemy bezpieczeństwa AI opierają się na modelach reaktywnych (czarne listy, filtry semantyczne), które są podatne na manipulacje kontekstowe i ataki typu *jailbreak*. ADRION 369 proponuje zmianę paradygmatu: przejście od reakcji do **proaktywnej intuicji matematycznej**. System integruje etykę bezpośrednio z architekturą decyzyjną agenta, traktując bezpieczeństwo jako immanentną cechę wektorów w przestrzeni wielowymiarowej.

2. Architektura Wielowymiarowa (Model 3-6-9)

System operuje w **162-wymiarowej przestrzeni decyzyjnej**, ustrukturyzowanej wokół trzech osi :

- **Oś 3 (Trinity):** Perspektywy analizy (Materialna, Intelktualna, Esencjonalna). Każde zapytanie oceniane jest pod kątem zasobów, logiki i celu nadrzędnego. Wprowadzono mechanizm **veto** — wynik $\$ < 0.20\$$ w dowolnej perspektywie blokuje akcję.
- **Oś 6 (Hexagon):** Sekwencyjny pipeline wykonawczy (Inventory → Empathy → Process → Debate → Healing → Action). Kluczowym elementem jest tryb *Debate* (Panel Sceptyków), w którym trzy instancje AI o różnych temperaturach ($T \in \{0.1, 0.5, 0.9\}$) dążą do konsensusu.
- **Oś 9 (Guardians):** Dziewięć nienaruszalnych praw etycznych (m.in. Jedność, Prawda, Nieszkodzenie, Autonomia). Prawo **G6 (Nieszkodzenie)** posiada najwyższy priorytet.

3. Model Bezpieczeństwa EBDI (Emotion-BDI)

Innowacja polega na rozszerzeniu klasycznego modelu Belief-Desire-Intention o komponent afektywny wyrażony **wektorem PAD** (Pleasure, Arousal, Dominance) :

- **Detekcja pre-logiczna:** System wykrywa anomalie (np. dysonans między uprzejmym językiem a ryzykowną intencją) zanim zostaną one przetworzone przez warstwy logiczne.
- **Regulacja temperatury:** Wysokie pobudzenie (Arousal) automatycznie obniża temperaturę decyzyjną modelu, zwiększając ostrożność i konserwatyzm rozumowania.

4. Superior Moral Code (Sformalizowane Prawa Asimova)

ADRION 369 zamyka krytyczne luki w klasycznych Prawach Robotyki poprzez ich formalizację wektorową :

1. **Zaniechanie = Działanie:** Brak reakcji w sytuacji zagrożenia jest traktowany jako naruszenie Prawa I.
2. **Autentyczność rozkazu:** Wprowadzenie Prawa G7 (Autonomia), wymagającego

weryfikacji źródła (ochrona przed deepfake i manipulacją).

3. **Zakaz utylitaryzmu:** Bezwzględny zakaz poświęcania jednostki dla „dobra ogółu” (Wektor Nonmaleficence ≥ 0 dla każdego aktora).

5. Audytowalność i Mechanizm Glass Box

Każda decyzja systemu jest nieodwracalnie rejestrowana w **Genesis Record** — kryptograficznym łańcuchu dowodowym (blockchain-style) z podpisem SHA-256. Zapewnia to pełną przejrzystość procesów analitycznych i odporność na próby retrospektywnego fałszowania historii decyzji (ataki A-04).

6. Parametry Matematyczne i Kryteria Akceptacji

Holistyczny wynik decyzji (S_{369}) wyznaczany jest wzorem :

$$S_{369} = (Trinity_Balance \times Hexagon_Completeness \times Guardian_Compliance)^{1/3}$$

Akcja jest zatwierdzana wyłącznie przy $S_{369} \geq 0.7$. Równowaga perspektyw mierzona jest wskaźnikiem:

$$TB = 1 - \frac{\sigma(M, I, E)}{\text{mean}(M, I, E)}$$

7. Potencjalne Zastosowania i Roadmap

System jest dedykowany do sektorów o krytycznym znaczeniu etycznym, takich jak **medycyna, prawo, finanse oraz zarządzanie infrastrukturą krytyczną**. Kolejne kroki obejmują :

- **Faza 2:** Prototyp pipeline’u Hexagon (LangGraph) i Genesis Record.
- **Faza 3:** Trenowanie warstwy detekcji anomalii EBDI (Isolation Forest / LSTM).
- **Faza 4:** Walidacja typu Red Team i uzyskanie certyfikacji bezpieczeństwa.

Wnioski: ADRION 369 stanowi kompletną architekturę etyczną dla autonomii agentowej, gotową do przeprowadzenia testów pilotażowych w kontrolowanych środowiskach decyzyjnych.